

粒状性を考慮したラフ集合ベースの 混合多項分布型共クラスタリングに基づく協調フィルタリング

Collaborative Filtering Based on Rough Set-Based Co-clustering
Induced by Multinomial Mixture Models Considering Uncertainty

○ 毛利 憲竜¹, 生方 誠希¹, 本多 克宏¹
○ Kenryu Mouri¹, Seiki Ubukata¹, Katsuhiro Honda¹
¹ 大阪公立大学

¹Osaka Metropolitan University

Abstract: In clustering-based collaborative filtering (CF), clusters of users with similar preference patterns are extracted, and items with high preferences within the cluster are recommended. Since data in CF tasks contain uncertainties arising from human sensibilities, represented as co-occurrence relationships between users and items, approaches such as rough clustering and co-clustering can be effective. Thus, rough co-clustering induced by multinomial mixture models (RCCMM) and its application to CF (RCCMM-CF) have been proposed. However, RCCMM has a problem in that it does not consider the granularity, an important viewpoint in rough set theory. In this study, we propose a CF approach based on rough set-based co-clustering induced by multinomial mixture models (RSCCMM) considering granularity. Furthermore, we verify the recommendation performance of the proposed method through numerical experiments using real-world datasets.

1 はじめに

協調フィルタリング (Collaborative Filtering, CF) は、各ユーザーに対し、他のユーザーの趣味嗜好に基づいて好ましいコンテンツの推薦を行う手法であり、コンテンツ推薦システムで広く活用されている。データ内の対象を教師なしで分類・要約する技術であるクラスタリングに基づく CF は実装が容易であり、効率的に計算ができることに加えて、メモリ消費量を低減できるという利点がある。代表的なクラスタリング手法として、Hard C -Means (HCM; k -Means) 法 [1] がある。HCM 法では、各対象は唯一のクラスターに帰属するよう、排他的な分割が行われるが、CF が対象とするユーザーの嗜好情報は人間の主観的な評価に基づいており、不確実性を含んでいる。したがって、ラフ集合理論 [2] に基づいて不確実性を取り扱うラフクラスタリングが有効であると考えられる。ラフクラスタリングは、対象のクラスターに対する帰属の確実性・可能性・不確実性を考慮することにより、一つの対象の複数のクラスターに対する帰属を表現でき、クラスターのオーバーラップを取り扱える。ラフクラスタリングのアルゴリズムとしては、Generalized Rough C -Means (GRCM) 法、Rough Set C -Means (RSCM) 法、Rough Membership C -Means (RMCM) 法など、様々な手法が提案されている [3]。また、これらのラフクラスタリング手法をベースにした CF が提案されている [4, 5, 6]。

文書におけるキーワードの頻度、ユーザーの購買履歴などの対象と項目間の共起情報を表す共起関係データのクラスタリングにおいて、関連性の強い対象と項目の組からなる共クラスタを抽出する共クラスタリングが注目されている。CF で扱うデータはユーザー

×アイテムの共起関係データと考えられ、共クラスタリングによる分析が有効であると考えられる。共クラスタリングの手法としてファジィ理論に基づく Fuzzy Co-Clustering induced by Multinomial Mixture models (FCCMM) 法 [7] やラフ集合理論に基づく Rough CCMM (RCCMM) 法 [8] がある。また、RCCMM 法に基づく CF (RCCMM-CF) が提案されている [9]。RCCMM 法はラフ集合理論において重要な概念である対象空間の粒状性を考慮しておらず、ラフ近似を定義通りに使用していないという問題があるため、Ubukata *et al.* は、対象空間の粒状性を考慮したラフ共クラスタリング手法として Rough Set CCMM (RSCCMM) 法 [10] を提案した。

本研究では、RSCCMM 法に基づく協調フィルタリング (RSCCMM-CF) を提案し、実データを用いた数値実験を通してその推薦性能を検証する。

2 準備

2.1 HCM 法

n 個の対象からなる全体集合 $U = \{\mathbf{x}_1, \dots, \mathbf{x}_i, \dots, \mathbf{x}_n\}$ から C 個のクラスターを抽出する問題を考える。各対象は m 次元ベクトル $\mathbf{x}_i = (x_{i1}, \dots, x_{ij}, \dots, x_{im})^\top$ で表され、各クラスター c はクラスター中心 $\mathbf{b}_c = (b_{c1}, \dots, b_{cj}, \dots, b_{cm})^\top$ を持つとする。

HCM 法のアルゴリズムを以下に示す。

Step 1 クラスター数 C を設定する。

Step 2 C 個の初期クラスター中心 \mathbf{b}_c を対象空間 U の中から非復元抽出により決定する。

Step 3 対象 i のクラスター c に対するメンバシップ u_{ci}

を最近隣割り当てによって求める。

$$d_{ci} = \|\mathbf{x}_i - \mathbf{b}_c\|, \quad (1)$$

$$d_i^{\min} = \min_{1 \leq l \leq C} d_{li}, \quad (2)$$

$$u_{ci} = \begin{cases} 1 & (d_{ci} \leq d_i^{\min}), \\ 0 & (\text{otherwise}). \end{cases} \quad (3)$$

Step 4 クラスタ中心 \mathbf{b}_c を計算する。

$$\mathbf{b}_c = \frac{\sum_{i=1}^n u_{ci} \mathbf{x}_i}{\sum_{i=1}^n u_{ci}}. \quad (4)$$

Step 5 u_{ci} に変化がなくなるまで **Step 3-4** を繰り返す。

2.2 RCM 法

RCM 法は、HCM 法をラフ集合理論によって拡張した手法であり、クラスタのオーバーラップ度合いを調節するパラメータを用いて、HCM 法の最近隣割り当て ((3) 式) の条件を緩和し、複数のクラスタへの帰属を表現することができる。本研究では、GRCM 法において正規化メンバシップを用いてクラスタ中心を算出する GRCM with Membership Normalization (GRCM-MN) 法 [3] を採用し、単に RCM 法とよぶ。

RCM 法のアルゴリズムを以下に示す。

Step 1 クラスタ数 C 、クラスタのオーバーラップ度合いを調節するパラメータ $\alpha \geq 1, \beta \geq 0$ を設定する。

Step 2 C 個の初期クラスタ中心 \mathbf{b}_c を対象空間 U の中から非復元抽出により決定する。

Step 3 対象 i のクラスタ c の上エリアに対するメンバシップ \bar{u}_{ci} と正規化メンバシップ \tilde{u}_{ci} を順に以下の式で求める。

$$\bar{u}_{ci} = \begin{cases} 1 & (d_{ci} \leq \alpha d_i^{\min} + \beta), \\ 0 & (\text{otherwise}), \end{cases} \quad (5)$$

$$\tilde{u}_{ci} = \frac{\bar{u}_{ci}}{\sum_{l=1}^C \bar{u}_{li}}. \quad (6)$$

Step 4 クラスタ中心 \mathbf{b}_c を計算する。

$$\mathbf{b}_c = \frac{\sum_{i=1}^n \tilde{u}_{ci} \mathbf{x}_i}{\sum_{i=1}^n \tilde{u}_{ci}}. \quad (7)$$

Step 5 \bar{u}_{ci} に変化がなくなるまで **Step 3-4** を繰り返す。

2.3 RSCM 法

RSCM 法は粒状性を考慮したラフクラスタリングであり、 U 上の二項関係 $R \subseteq U \times U$ を用いて、対象空間の粒状化を行う。各対象を R による近傍に基づいてクラスタ割り当てを行うことで、確実性・可能性・不確実性を取り扱う。 $n \times n$ の行列要素を用いて、対象間の関係の有無を次式で表す：

$$R_{it} = \begin{cases} 1 & (x_i R x_t), \\ 0 & (\text{otherwise}). \end{cases} \quad (8)$$

RSCM 法のアルゴリズムを以下に示す。

Step 1 クラスタ数 C 、二項関係 $R \subseteq U \times U$ を設定する。

Step 2 C 個の初期クラスタ中心 \mathbf{b}_c を対象空間 U の中から非復元抽出により決定する。

Step 3 暫定クラスタに対するメンバシップ u_{ci} を (3) 式で求める。

Step 4 対象 i のクラスタ c に対するラフメンバシップ値 μ_{ci}^R と上近似に対するメンバシップ \bar{u}_{ci} を順に以下の式で計算し、正規化メンバシップ値 \tilde{u}_{ci} を (6) 式で計算する。

$$\mu_{ci}^R = \frac{\sum_{t=1}^n R_{it} u_{ct}}{\sum_{t=1}^n R_{it}} \quad (9)$$

$$\bar{u}_{ci} = \begin{cases} 1 & (\mu_{ci}^R > 0), \\ 0 & (\text{otherwise}). \end{cases} \quad (10)$$

Step 5 クラスタ中心 \mathbf{b}_c を (7) 式で計算する。

Step 6 u_{ci} に変化がなくなるまで **Step 3-5** を繰り返す。

2.4 共クラスタリング

共クラスタリングでは、対象と項目の共起関係を表す共起関係データから、親近性の高い対象と項目の組からなる共クラスタを抽出する。対象 i と項目 j の共起度を r_{ij} 、対象 i の共クラスタ c に対するメンバシップを u_{ci} 、項目 j の共クラスタ c に対するメンバシップを w_{cj} 、対象数を n 、項目数を m とする。以下で共クラスタリング手法である HCCMM 法と RCCMM 法、RSCCMM 法について説明する。

2.4.1 HCCMM 法

HCCMM 法は FCCMM 法において、対象の分割に関してハードであり、項目のメンバシップ値のファジィ度

を考慮しない特殊なモデルである。HCCMM 法の最適化問題は以下で与えられる。

$$\max. \quad J_{\text{HCCMM}} = \sum_{c=1}^C \sum_{i=1}^n \sum_{j=1}^m u_{ci} r_{ij} \log w_{cj}, \quad (11)$$

$$\text{s.t.} \quad u_{ci} \in \{0, 1\}, w_{cj} \in (0, 1], \forall c, i, j, \quad (12)$$

$$\sum_{c=1}^C u_{ci} = 1, \forall i, \quad \sum_{j=1}^m w_{cj} = 1, \forall c. \quad (13)$$

クラスター c と対象 i の類似度 s_{ci} を次式で定める。

$$s_{ci} = \sum_{j=1}^m r_{ij} \log w_{cj}. \quad (14)$$

ここで、 $s_{ci} \leq 0$ となる点に注意する。 s_{ci} が大きいほど類似度が大きい。

HCCMM 法のアルゴリズムを以下に示す。

Step 1 クラスター数 C を設定する。

Step 2 項目メンバシップ w_{cj} を次のように初期化する。ランダムに C 個の対象をサンプリングし、総和が 1 となるように正規化する。

$$w_{cj} = \frac{r_{cj}}{\sum_{l=1}^m r_{cl}}. \quad (15)$$

Step 3 対象 i のクラスター c に対するメンバシップ u_{ci} を、最も類似度の大きいクラスターとの類似度 s_i^{\max} に基づいて計算する。

$$s_i^{\max} = \max_{1 \leq c \leq C} s_{ci}, \quad (16)$$

$$u_{ci} = \begin{cases} 1 & (s_{ci} \geq s_i^{\max}), \\ 0 & (\text{otherwise}). \end{cases} \quad (17)$$

Step 4 項目メンバシップ w_{cj} を更新する。

$$w_{cj} = \frac{\sum_{i=1}^n u_{ci} r_{ij}}{\sum_{l=1}^m \sum_{i=1}^n u_{ci} r_{il}}. \quad (18)$$

Step 5 u_{ci} に変化がなくなるまで **Step 3-4** を繰り返す。

2.4.2 RCCMM 法

RCCMM 法は HCCMM 法にラフ集合理論の観点を導入したラフ共クラスタリング手法である。RCCMM 法では、クラスター割り当てにおいて、クラスターのオーバーラップ度合いを調節するパラメータを用いて、1 次関数の閾値を減少させることにより、HCCMM 法の割り当て ((17) 式) の条件を緩和し、複数の上エリア

への帰属を表現することができる。本研究では、正規化メンバシップに基づいて項目メンバシップを計算する RCCMM-MN 法を採用し、単に RCCMM 法と書く。

RCCMM 法のアルゴリズムを以下に示す。

Step 1 クラスター数 C 、クラスターのオーバーラップ度合いを調節するパラメータ $\alpha \geq 1, \beta \leq 0$ 、を設定する。

Step 2 ランダムに C 個の対象をサンプリングし、項目メンバシップ w_{cj} を (15) 式によって初期化する。

Step 3 対象 i のクラスター c の上エリアに対するメンバシップ \bar{u}_{ci} を以下の式で計算し、(6) 式で正規化メンバシップを求める。

$$\bar{u}_{ci} = \begin{cases} 1 & (s_{ci} \geq \alpha s_i^{\max} + \beta), \\ 0 & (\text{otherwise}). \end{cases} \quad (19)$$

Step 4 項目メンバシップ w_{cj} を更新する。

$$w_{cj} = \frac{\sum_{i=1}^n \bar{u}_{ci} r_{ij}}{\sum_{l=1}^m \sum_{i=1}^n \bar{u}_{ci} r_{il}}. \quad (20)$$

Step 5 \bar{u}_{ci} に変化がなくなるまで **Step 3-4** を繰り返す。

2.4.3 RSCCMM 法

RSCCMM 法は対象空間の粒状性を考慮したラフ共クラスタリング手法である。本研究では、正規化メンバシップに基づいて項目メンバシップを計算する RSCCMM-MN 法を採用し、単に RSCCMM 法と書く。

RSCCMM 法のアルゴリズムを以下に示す。

Step 1 クラスター数 C 、二項関係 $R \subseteq U \times U$ を設定する。

Step 2 ランダムに C 個の対象をサンプリングし、項目メンバシップ w_{cj} を (15) 式によって初期化する。

Step 3 暫定クラスターに対するメンバシップ u_{ci} を (17) 式で求める。

Step 4 対象 i のクラスター c に対するラフメンバシップ値 μ_{ci}^R と上近似に対するメンバシップ \bar{u}_{ci} 、正規化メンバシップ \tilde{u}_{ci} を (9), (10), (6) 式で順に求める。

Step 5 項目メンバシップ w_{cj} を (20) 式で更新する。

Step 6 u_{ci} に変化がなくなるまで **Step 3-5** を繰り返す。

2.5 RCCMM-CF

RCCMM-CF[9] は、評価値行列 $X = \{r_{ij}\}$ に RC-CMM 法を適用することで、共起関係データに内在する、人間の感性に起因する不確実性を考慮しながら、嗜好の類似したユーザーのクラスターを抽出し、クラスター内で嗜好度の高いコンテンツを推薦する手法である。

RCCMM-CF の手順を以下に示す。

Step 1 $n \times m$ の評価値行列 $X = \{r_{ij}\}$ に対して RC-CMM 法を適用し、正規化ユーザーメンバシップ \tilde{u}_{ci} とアイテムメンバシップ w_{cj} を求める。

Step 2 ユーザー i に対するアイテム j の推薦度 \hat{r}_{ij} を計算する。

$$\hat{r}_{ij} = \sum_{c=1}^C \tilde{u}_{ci} w_{cj}. \quad (21)$$

Step 3 閾値 $\eta \in [\min\{\hat{r}_{ij}\}, \max\{\hat{r}_{ij}\}]$ 以上の推薦度を持つアイテムを推薦する。

$$\check{r}_{ij} = \begin{cases} 1 & (\hat{r}_{ij} \geq \eta), \\ 0 & (\text{otherwise}). \end{cases} \quad (22)$$

3 提案法：RSCCMM-CF

本研究では、対象空間の粒状性を考慮したラフ共クラスタリングに基づく協調フィルタリングとして、RSCCMM-CF を提案する。RSCCMM-CF は、対象空間の粒状化を通して、ラフ集合理論におけるラフ近似を定義通りに使用して推薦を行う。

対象空間を粒状化するため、対象間の二項関係を設定する。まず、二項関係を構成するための対象間の類似度を定義する。共起関係データに適した類似度を考えるため、HCCMM 法における対象 i とクラスター c の類似度 ((14)) 式を参考に、対象 i と対象 t の類似度 S_{it} を定義する。項目メンバシップは混合多項分布から派生したものであるため、確率分布を基礎とした類似度を考える。そこで、各対象について共起情報の総和が 1 となるように正規化した \tilde{r}_{ij} を考慮し、各対象の共起情報を確率分布として捉える：

$$\tilde{r}_{ij} = \frac{r_{ij}}{\sum_{l=1}^m r_{il}}. \quad (23)$$

対象 i と対象 t の類似度 S_{it} を下記のように定義する：

$$S_{it} = \sum_{j=1}^m \tilde{r}_{tj} \log \tilde{r}_{ij}. \quad (24)$$

これは、負の交差エントロピーとみなせる。類似度 S_{it} に基づき、二項関係を以下のように設定する：

$$R_{it} = \begin{cases} 1 & (S_{it} \geq \delta), \\ 0 & (\text{otherwise}). \end{cases} \quad (25)$$

ここで、 $\delta \leq 0$ はラフさを調節するパラメータであり、 δ が小さいほど粗い粒状化となり、上近似が拡大し、クラスターのオーバーラップが大きくなる。一般に、 S_{it} は非対称であり、 R_{it} は対称性を満たさない。

RSCCMM-CF の手順を以下に示す。

Step 1 ラフさを調節するパラメータ $\delta \leq 0$ を設定し、 $n \times m$ の評価値行列 $X = \{r_{ij}\}$ に対して、対象間の二項関係を (25) 式によって定る。RSCCMM 法を適用し、正規化ユーザーメンバシップ \tilde{u}_{ci} とアイテムメンバシップ w_{cj} を求める。

Step 2 ユーザー i に対するアイテム j の推薦度 \hat{r}_{ij} を (21) 式で計算する。

Step 3 閾値 $\eta \in [\min\{\hat{r}_{ij}\}, \max\{\hat{r}_{ij}\}]$ 以上の推薦度を持つアイテムを (22) 式で推薦する。

4 数値実験

2 種類の実データ (NEEDS-SCAN/PANEL データおよび MovieLens-100k データ) に対して提案法を適用し、様々なパラメータ設定において、ROC-AUC 指標によって推薦性能を検証した。

4.1 実験データ

4.1.1 NEEDS-SCAN/PANEL

NEEDS-SCAN/PANEL データは日本経済新聞社が収集した、2000 年の調査対象の 996 世帯 (ユーザー) の 18 種類の製品 (アイテム) に対しての所有の有無を表すデータである。評価値 r_{ij} はユーザー i がアイテム j を所有している場合 1、所有していない場合 0 となる。このデータの中でランダムに選んだ 1,000 個をテストデータとし、テストデータに対する評価値を未評価値として 0 に置き換えたデータをトレーニングデータとして、実験を行った。

4.1.2 MovieLens-100k

MovieLens-100k データは GroupLens Research (<https://grouplens.org/>) が収集した、943 人のユーザーが 1,682 本の映画に対して行った 100,000 個の評価値のデータである。各評価は、1 ~ 5 の 5 段階評価である。本実験では、このうち 30 本以上の映画を評価した $n = 690$ のユーザーと、50 人以上のユー




図 1: NEEDS-SCAN/PANEL: 各 C における δ による AUC の変化 (RSCM-CF)

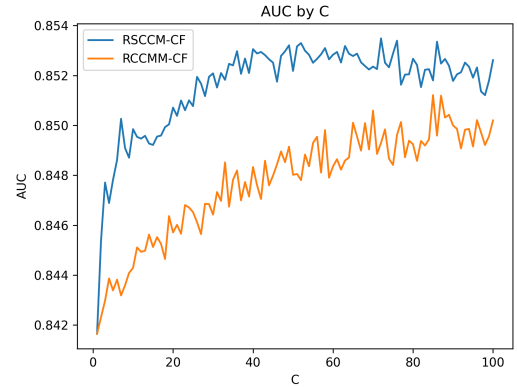


図 2: NEEDS-SCAN/PANEL: C による AUC の変化 (RSCM-CF と RSCM-CF)

ザーが評価した $m = 583$ の映画を抽出し、77,201 個の評価を含むデータを作成して使用した。そのうちの約 10% である 7,720 個の評価をテストデータとし、テストデータに対する評価値を未評価値の値に置き換えたデータをトレーニングデータとした。元の評価値が 4 以上であれば $r_{ij} = 1$, 3 以下であれば $r_{ij} = 0$ に置き換え、未評価値は $r_{ij} = 0.5$ としたデータを作成して実験を行った。

4.2 評価指標

推薦性能は ROC-AUC 指標によって評価した。ROC (Receiver Operating Characteristic) 曲線は、種々の閾値での偽陽性率に対する真陽性率をプロットすることで得られ、AUC (Area Under the Curve) は ROC 曲線の下部の面積である。AUC はランダムな推薦のとき 0.5 程度になり、1 に近いほど推薦性能が良いといえる。

4.3 実験結果

4.3.1 NEEDS-SCAN/PANEL

各クラスター数 $C \in \{1, 2, 3, 5\}$ における δ による AUC の変化を図 1 に示す。各 AUC の値は、 $\delta \in [-15.0, -5.0]$ を 0.5 刻みで変化させた時の、異なる初期値による 10 回試行の平均である。 δ は小さいとき粗い粒状化、大きいとき細かい粒状化を表す。 $C = 1$ の時は各製品の所有の有無の平均値が全世帯に対する推薦度となり、 δ の値に依存せず、AUC は 0.8416 である。 $C = \{2, 3, 5\}$ の場合、 δ を減少させて粗い粒状化にしていくと、AUC は $C = 1$ の場合に比べて高い値となり、その後減少し、収束していくことがわかる。

提案法 (RSCM-CF) と従来法 (RSCM-CF) について、 C を 1 から 100 まで変化させた時の AUC




図 3: MovieLens-100k: 各 C における δ による AUC の変化 (RSCM-CF)

の変化を図 2 に示す。各 AUC は、RSCM-CF では $\delta \in [-10.0, -5.0]$ を 0.5 刻み、RSCM-CF では $\alpha \in [1.0, 1.6]$ を 0.05 刻み、 $\beta \in [-10.0, 0.0]$ を 1.0 刻みで変化させたときの、異なる初期値による 10 回試行の平均値から最大値を採用した。いずれの手法も C の増加に伴い AUC が向上する傾向がみられ、いずれの C においても、RSCM-CF が高い AUC を達成した。

4.3.2 MovieLens-100k

各 $C \in \{1, 2, 3, 5\}$ における δ による AUC の変化を図 3 に示す。各 AUC の値は $\delta \in [-12.0, -6.5]$ を 0.5 刻みで変化させたときの、異なる初期値による 10 回試行の平均である。 $C = 1$ の時は各映画の評価値の平均値が全てのユーザーに対する推薦度となり、 δ の値に依存せず、AUC は 0.6940 である。 $C = \{2, 3, 5\}$ の場合、 δ の減少にともなって、AUC は $C = 1$ の場合に比べて高い




図 4: MovieLens-100k: C による AUC の変化 (RCCMM-CF と RSCMM-CF)

値となり、その後減少し、収束していくことがわかる。

提案法と従来法について、 C を 1 から 30 まで変化させた時の AUC の変化を図 4 に示す。各 AUC は RSCMM-CF では $\delta \in [-11.0, -6.5]$ を 0.3 刻み、RCCMM-CF では $\beta = 0$ に固定し、 $\alpha \in [1.000, 1.001]$ を 0.0001 刻みで変化させたときの、異なる初期値による 10 回試行の平均値から最大値を採用した。いずれの手法も C の増加に伴い AUC が向上した後に減少する傾向がみられ、いずれの C においても、RSCMM-CF が高い AUC を達成した。

5 おわりに

本研究では、協調フィルタリングタスクにおいて共クラスタリングにラフ集合理論の粒状性の観点を取り入れた RSCMM-CF 法を提案し、実データを用いた数値実験を通して推薦性能を検証した。結果から両データセットにおいてパラメータ δ を調節することにより、従来法である RCCMM-CF より高い推薦性能を達成でき、共起関係データに内在するオーバーラップしたクラスター構造を適切に抽出できることが示唆された。また、提案法は従来法に比べパラメータの数が少なく、設定が容易で、広い範囲のパラメータ設定で安定して高い推薦性能を出せることがわかった。今後の課題として、データの特徴に応じたその他の粒状化手法の検証、ノイズの低減、パラメータの決定基準の導入などが挙げられる。

なお、本研究の一部は、JSPS 科研費 JP20K19886 の助成に基づいて行われたものである。

参考文献

- [1] J. MacQueen: Some Methods of Classification and Analysis of Multivariate Observations, Proc. of 5th

Berkeley Symposium on Mathematical Statistics and Probability, 281-297 (1967)

- [2] Z. Pawlak: Rough Sets, International Journal of Computer & Information Sciences, 11, 5, 341-356 (1982)
- [3] 生方 誠希: ラフ集合に基づく C-Means 型クラスタリングの展開, 日本知能情報ファジィ学会誌, 32, 4, 121-127 (2020)
- [4] S. Ubukata, S. Takahashi, A. Notsu, and K. Honda: Basic Consideration of Collaborative Filtering Based on Rough C-Means Clustering, Proc. of Joint 11th International Conference on Soft Computing and Intelligent Systems and 21st International Symposium on Advanced Intelligent Systems, 256-261 (2020)
- [5] S. Ubukata, Y. Murakami, A. Notsu, and K. Honda: Basic Consideration of Collaborative Filtering Based on Rough Set C-means Clustering, Proc. of 22nd International Symposium on Advanced Intelligent Systems, #OS19-4 (2021)
- [6] H. Kim, S. Ubukata, A. Notsu, and K. Honda: Two Types of Collaborative Filtering Based on Rough Membership C-Means Clustering, Proc. of 22nd International Symposium on Advanced Intelligent Systems, 1-6 (2021)
- [7] K. Honda, S. Oshio, and A. Notsu: Fuzzy Co-clustering Induced by Multinomial Mixture Models, Journal of Advanced Computational Intelligence and Intelligent Informatics, 19, 6, 717-726 (2015)
- [8] S. Ubukata, N. Nodake, A. Notsu, and K. Honda: Basic Consideration of Co-clustering Based on Rough Set Theory, Proc. of 8th International Symposium on Integrated Uncertainty in Knowledge Modelling and Decision Making, 151-161 (2020)
- [9] S. Ubukata, K. Mouri, and K. Honda: Basic Consideration of Collaborative Filtering Based on Rough Co-clustering Induced by Multinomial Mixture Models, Proc. of 2022 Joint 12th International Conference on Soft Computing and Intelligent Systems and 23rd International Symposium on Advanced Intelligent Systems (SCIS&ISIS), 1-6 (2022)
- [10] 野岳 就拓, 生方 誠希, 野津 亮, 本多 克宏: ラフ集合理論に基づく粒状性を考慮した共クラスタリングに関する一検討, インテリジェント・システム・シンポジウム講演論文集, 354-359 (2021)

連絡先

〒 599-8531 大阪府堺市中区学園町 1-1

大阪公立大学 大学院情報学研究科 生方 誠希

TEL: 072-254-9355

E-mail: ubukata@omu.ac.jp